범 한 철 학 회 논 문 집
『범한철학』 제115집 2024년 겨울
https://doi.org/10.22932/pkps.2024.115.4.151

로봇과 인간의 우정은 가능한가?
-로봇의 도덕적 지위와 인간성의 의미-

이 원 봉*

【주제분류】 응용윤리, 윤리학
【주 요 어】 인공지능 로봇, 우정, 도덕적 지위, 칸트 윤리학, 인간성의 정식
【요 약 문】
인공지능의 합리적 추론 능력이 발전하고, 인공지능과 결합한 휴머노이드 로봇이 기쁨이나 분노와 같은 섬세한 감정을 표현할 수 있게 되면서 로봇과 인간 사이의 경계가 모호해지고 있다. 특히 인간과 친밀한 관계를 맺는 것을 목표로 하는 사회적 로봇의 경우, 이 로봇의 도덕적 지위를 둘러싸고 다양한 논쟁이 전개되고 있다. 로봇은 인간과 사랑이나 우정을 나눌 수 있는가? 만약 로봇과 인간 사이에 사랑이나 우정이 가능하다면, 진지한 사랑이나 우정의 상대인 로봇을 단순히 도구로 대우하는 것은 비도덕적일 것이고, 로봇을 인간과 동등한 존재로 인정해야 할 것이다. 만약 로봇이 인간과 동등한 도덕적 지위를 갖게 된다면, 인간과 로봇의 관계는 지금까지와는 전혀 다른 새로운 단계에 들어서게 될 것이다. 엘더(Alexis Elder)는 프로그램 된 대로 반응하는 로봇은 그 반응이 아무리 정교하다고 해도 내면의 의식이 없기 때문에 우정이 요구하는 '진정한 상호성'을 줄 수 없다고 주장한다. 하지만 다너허(John Danaher)는 우정에서 중요한 것은 확인 불가능한 의식이 아니라, 진정한 친구라면 해야 할 행동을 일관되게 하는 것 뿐이며, 현재나 가까운 미래의 로봇은 우정이 요구하는 행동을 할 수 있다고 주장한다. 엘더와 다나허로 대변되는 두가지 상반되는 입장은 로봇과의 우정의 가능성, 혹은 로봇의 도덕적 지위를 '의식'의 유무에 근거 짓고 있다. 한편에서 로봇은 의식이 없으므로 도덕적 주체가 될 수 없고 진정한 친구가 될 수 없다고 주장하고, 다른 한편에서는 의식을 경험적으로 확인할 방법이 없으므로 도덕적 존재로 인정받는 인간과 유사한 행동을 하는 로봇은 인간과 동등한 도덕적 지위를 가져야 한다고 주장한다. 하지만 우리는 과연 의식의 존재만으로 도덕적 지위가 보장될 수 있는지 물을 수 있다. 칸트에 따르면, 의식은 도덕적 지위를 위한 필수조건이지만 충분조건은 아니다. 어떤 존재가 자신의 욕망을 의식하고 실현하기 위해 노력할 수 있다고 해도, 자기의 욕망의 동기 자체를 반성할 수 없다

* 가톨릭대학교 학부대학 교수

www.kci.go.kr

면 도덕적 존재가 될 수 없다. 따라서 칸트의 도덕적 존재로서의 인간성 개념은 의식의 유무를 중심으로 전개되는 로봇의 도덕적 지위에 대한 논쟁에 다른 방향을 제시할 수 있을 것으로 보인다. 이 글은 로봇의 도덕적 지위를 의식에 근거한 도덕적 속성에서 찾는 입장과(2장) 도덕적 속성이 아니라 관계나 행동에서 찾는 입장을(3장) 비판적으로 검토할 것이다. 그리고 이것을 통해서 도덕적 지위의 근거는 단순히 의식이라는 내적 속성이 아니라, 도덕적 목적 설정 능력으로서의 의식에 있다는 것을 칸트의 인간성의 정식에 나타난 목적 개념을 통해서 주장할 것이다(4장).

1. 들어가는 말

최근 인간과 유사한 형태를 가졌을 뿐 아니라, 인공지능의 합리적 추론 능력과 함께 기쁨이나 분노와 같은 섬세한 감정 표현도 할 수 있는 휴머노이드 로봇이 등장하면서 로봇과 인간 사이의 친밀한 관계를 둘러싼 논쟁도 활발해지고 있다. 인간의 모습을 하고 정교한 반응을 하는 로봇은 인간과 진정한 의미의 사랑을 나눌 수 있는가? 연인 로봇은 단지 인간의 성적 만족을 위한 정교한 도구일 뿐인가? 또는 인간과 로봇 사이에도 진정한 친구관계가 가능한가? 친구 로봇은 외로움을 달래거나 교제의 즐거움을 얻기 위한 수단일 뿐인가? 이런 물음이 중요한 이유는 만약 로봇과 인간 사이에 진정한 사랑이나 우정이 가능하다면, 진정한 사랑이나 우정의 의미에서 볼 때, 로봇을 단순히 도구로 사용할 수 없고 인간과 동등한 존재로 인정해야 하기 때문이다.

진정한 상호성을 바탕으로 한 사랑과 우정이 가능하기 위해서는 두 당사자가 동등한 도덕적 지위를 가져야 한다. 따라서 로봇과 인간의 우정이 가능하다면, 인간은 로봇에 대해 도덕적 의무를 지고 로봇에게 기본적 권리를 부여해야 한다. 이것은 인간과 로봇 관계의 전혀 새로운 단계를 의미한다. 물론 우리는 동물의 경우에 유비해서 로봇의 도덕적 지위 문제를 해결할 수도 있다. 이때 로봇은 동물과 마찬가지로 인간과 동등한 도덕적 행위자, 즉 도덕적 주체는 될 수 없고 단지 도덕적 피동자에 그칠 것이다. 하지만 로봇은 동물과

www.kci.go.kr

달리, 지적 능력과 감정 표현에 있어서 인간과 유사하거나 능가한다. 이런 존재를 인간과 동등한 도덕적 행위자로 인정하지 않는 이유는 무엇인가? 엘더(Alexis Elder)는 로봇은 프로그램된 대로 반응하기 때문에, 그 반응이 아무리 정교하다고 해도 우정이 요구하는 '진정한 상호성'을 줄 수 없다고 주장한다. 친구 역할을 하기로 고용된 배우가 친구 연기를 잘한다고 해서 진짜 친구가 될 수 없는 것과 마찬가지로 로봇의 우정은 우정의 진정한 가치를 가질 수 없다는 것이다. 하지만 그 배우가 완벽하게 연기하고 그가 배우라는 것을 알 수 있는 방법이 없다면, 가짜 친구와 진짜 친구를 어떻게 구별할 것인가? 다너허(John Danaher)는 로봇 뿐 아니라 인간의 경우에도 진심을 확인할 수 없기 때문에 우정에서 중요한 것은 진짜 친구라면 해야 할 행동 뿐이라고 주장한다. 행동을 기준으로 할 때, 먼 미래의 로봇이 아니라 가까운 미래, 혹은 현재의 로봇과도 진정한 우정이 가능하다는 것이다. 다나허에 따르면, 로봇이 친구가 될 수 없다는 주장은 확인될 수 없는 독단적 주장일 뿐이며, 우정이 요구하는 행동을 일관되게 하는 로봇을 우정의 영역에서 배제해야 할 이유가 없다.

엘더와 다나허로 대변되는 두 입장은 로봇과의 우정의 가능성, 혹은 로봇의 도덕적 지위를 '의식'의 유무에 근거 짓고 있다. 즉, 의식이 있다면, 로봇은 당연히 도덕적 지위를 가질 것이고 진정한 상호성도 가능할 것이다. 한편에서 로봇은 의식이 없으므로 도덕적 주체가 될 수 없고 진정한 친구가 될 수 없다고 주장하는 반면, 다른 한편에서는 의식을 경험적으로 확인할 방법이 없으므로 도덕적 존재로 인정받는 인간과 유사한 행동을 하는 로봇은 인간과 동등한 도덕적 지위를 가져야 한다고 주장한다. 하지만 우리는 관점을 달리해서, 과연 의식의 존재만으로 도덕적 지위가 보장될 수 있는지 물을 수 있다. 칸트에 따르면, 의식은 도덕적 지위를 위한 필수조건이지만 충분조건은 아니다. 어떤 존재가 자신의 욕망을 의식하고 실현하기 위해 노력할 수 있다고 해도, 그가 자기 욕망의 동기 자체를 반성할 수 없다면 도덕적 존재가 될 수 없다. 따라서 칸트의 도덕적 목적으로서의 인간성 개념은 의식의 유무를 중심으로 전개되는 로봇의 도덕적 지위에 대한 논쟁에 다른 방향을 제시할 수 있을 것으로 보

www.kci.go.kr

인다. 이 글은 로봇의 도덕적 지위를 의식에 근거한 도덕적 속성에서 찾는 입장과(2장) 도덕적 속성이 아니라 관계나 행위 자체에서 찾는 입장을(3장) 비판적으로 검토할 것이다. 그리고 이것을 통해서 도덕적 지위의 근거는 단순히 의식이라는 내적 속성이 아니라, 목적 설정 능력으로서의 의식에 있다는 것을 칸트의 인간성의 정식에 나타난 목적 개념을 통해서 주장할 것이다(4장).

2. 로봇의 도덕적 지위와 속성 실재론

엘더는 아리스토텔레스의 우정론을 바탕으로 로봇과 인간 사이의 도덕적 우정의 가능성을 부정한다. 아리스토텔레스의 덕의 우정에 있어서 핵심 조건은 '진정한 상호성(true reciprocity)'인데, 프로그램된 대로 행동하는 로봇은 우정의 행동을 모방하고 있을 뿐이기 때문에 이것을 기대할 수 없다는 것이다.[1] 그녀에 따르면, 로봇과의 친밀한 관계가 인간에게 여러가지로 유익할 수 있지만, 이것은 아리스토텔레스가 말하는 유용성과 즐거움의 우정일 뿐 진정한 의미의 우정이 될 수 없다.[2] 진정한 상호성은 상호이해와 감정적 반응과 교환이 있어야 하고, 이것을 위해서는 로봇에게 내적 속성, 즉 의식이 있어야 하지만 로봇에게는 이것이 불가능하다는 것이다.

엘더는 우정에서 중요한 것은 겉으로 드러난 행동이 아니라 그러한 행동을 하는 의도라는 것을 보여주기 위해 한가지 사고실험을 제안한다. 이른바 '트

1) A. Elder, *Friendship, Robots, and Social Media: False Friends and Second Selves*, (Routledge, 2019), 9장 5절 참조.

2) 아리스토텔레스는 우정을 불완전한 우정과 완전한 우정으로 구분한다. 젊은이가 빠지는 사랑인 즐거움의 우정과 노인이 자기에게 이익이 되는 것에 갖는 애착인 유용성의 우정은 불완전한 것이고, 덕스러운 성품의 교환이 이루어지는 덕의 우정이 완전한 것이다. 즐거움과 유용성의 우정이 단지 수단적인 가치만을 갖는 반면, 덕으로서의 우정은 "상호적인 호의와 선한 의지를 상호 존중과 상호간의 가치 공유를 추구하는 우정이다." 장미성, 「아리스토텔레스의 우정론: 『니코마코스 윤리학』 8, 9권을 중심으로」, 『인간.환경.미래』, 제28호(인제대학교 인간환경미래연구원, 2022), 72-73 참조.

루먼쇼' 사고실험에서, 당신은 A와 B 두 세계 중 하나를 선택할 수 있다. 다만 선택 이후에 살아가는 세계에서 당신은 그 사실을 완전히 잊게 된다. 세계 A에서 당신이 친구라고 생각하고 있는 사람은 고용된 사람으로 당신의 친구 역할을 완벽하게 연기하고 있을 뿐이다. 그리고 당신이 그것을 알아채는 것은 불가능하다. 세계 B에서 당신이 친구라고 생각하는 사람은 고용되지 않았다. 세계 A와 B는 친구가 고용되었다는 사실 이외는 다른 차이가 전혀 없다고 할 때, 당신은 분명 세계 B를 선택할 것이다. 우리가 친구에게서 바라는 것은 친구 역할을 하는 배우의 연기가 아니라, 상대와의 진정한 상호성의 교환이기 때문이다.[3)]

로봇과의 우정을 가짜 우정, 혹은 속임수 우정이라고 생각하는 입장은 엘더만이 아니다. 니홀름(Sven Nyholm)은 우정과 사랑을 포함한 모든 친밀한 관계는 진정한 상호성을 필요조건으로 요구하기 때문에, 만약 이런 진정한 상호성이 불가능한 로봇을 친구나 연인처럼 보이게 디자인한다면 사용자를 속이는 것이고, 사용자를 기만하는 로봇 제품은 도덕적으로 허용될 수 없다고 한다. 기만적인 친밀한 관계는 우정이나 사랑의 관계를 맺기 어려운 사람을 착취하는 것이고, 진정한 상호적 관계의 가능성을 축소시킬 것이기 때문이다.[4)]

로봇의 우정을 속임수로 보는 이런 '기만 이론'은 적어도 외적 행동과 그런 행동을 의도하는 내적 속성이 구별된다는 것을 전제한다.[5)] 인간 행위자는 일

3) A. Elder, "False Friends and False Coinage: A tool for navigating the ethics of sociable robots", in the *SIGCAS Computers and Society*, vol. 45(3)(2015), 250쪽 참조.. Elder는 아리스토텔레스의 가짜 화폐 유비를 가져와, 로봇의 가짜 우정은 마치 가짜 화폐와 같이 액면가는 동일하지만 실제 가치는 없다고 지적한다. Danaher는 Elder의 이런 사고실험에 대해, 인간 친구와 똑같이 행동하는 외계인과의 사이에 우정이 가능하다고 하면서, 생물학적 조건이 다르다고 해도 진정한 상호성이 가능하다고 한다. J. Danaher, "The Philosophical Case for Robot Friendship", in the *Journal of Posthuman Studies*, vol. 3(1)(2019), 11쪽 참조.

4) S. Nyholm/ L. E. Frank, "From Sex Robots to Love Robots: Is Mutual Love with a Robot Possible?", in the *Robot Sex: Scial and Ethical Implication*(MIT press, 2017), 223쪽 참조. "다른 행위자와의 상호교제가 문제일 때, 우리가 그들과 어떤 종류의 관계를 가질 수 있는지에 있어 가장 중요한 것은 '내부에서' 진행되고 있는 것이다."

반적으로 자신의 외적 행동과 그 행동을 의도하는 내적 경험이 일치하지 않을 수 있다는 것을 알고 있다. 인간은 누구나 상대를 자신의 은밀한 목적에 이용하려는 의도를 갖고 우정이 요구하는 행동들을 할 수 있다. 따라서 진정한 친구의 경우, 우정의 행동 뿐 아니라 그 행동의 의도가 진짜라야 하는 것이다. 하지만 로봇은 내적 경험을 할 수 있는 의식이 없기 때문에, 로봇과 인간 사이에 덕의 우정은 불가능하고, 기껏해야 유용성의 우정만이 가능할 뿐이다.[6]

인간과 로봇의 우정을 위해서는 내적 속성이 필요하다는 입장을 '속성 실재론'으로 부를 수 있는데,[7] 브라이슨(Joanna Brayson)은 로봇이 도덕적 지위의 근거가 되는 내적 속성을 가질 수 없는 이유를, 인간의 내적 속성이 생물학적 진화의 과정을 거치면서 형성된 것이라는 점에서 찾는다. 도덕적 속성은 로봇에게도 가능한 합리적 추론능력이 아니라, 사회적 동물인 인간에게 진화해 온 공감능력과 사회적 상호작용에서의 자율성이라는 것이다. 따라서 생물학적 진화과정은 이러한 내적 속성을 갖기 위한 필요조건인데, 인간에 의해 디자인되고 제작되는 로봇은 이것이 불가능하다. 그 이유는, 첫째 도덕적 판단을 위한 인간의 복잡한 인지능력은 다양한 문화적 배경을 통해 형성된 고유한 것이므로, 이런 능력을 동일하게 복제하는 것을 불가능하다. 둘째, 인간은 사회적 상황을 즉각적으로 파악하고 반응하는 지각능력을 생물학적으로 진화 시켜왔고, 이런 능력을 통해 인간은 사회적 상호작용을 하고 도덕적 딜레마를 이해하면서 도덕적 결정을 내릴 수 있다. 그리고 마지막으로 인간은 이러한 능력

5) 프로그램 된 대로 움직이는 로봇은 숨겨진 목적을 갖지 않지만, 그렇다고 해서 상대를 진심으로 생각한다는 내적 경험을 가질 수도 없다. 이것을 로봇의 입장에서 기만이라고 할 수는 없지만, 사용자는 로봇의 행위를 우정으로 생각함으로써 로봇 제작자에게 기만 당하고 있다고 할 수 있다.

6) 다만Elder와 Nyholm은 미래의 로봇이 의식을 가질 수 있는지에 대해는 깊게 다루지 않지만, 내적 속성으로서의 의식은 모든 인간이 공유하는 생물학적 속성에 근거하고 있다고 한다.

7) Coeckelbergh는 기계의 도덕적 지위 질문에 답하는 접근 방식을 크게 도덕 속성 실재론과 관계론적 접근 두 가지로 구분하고 있다. M. Coeckelbergh, *Robots and the Moral Landscape*(Routledge, 2020) 1-2장 참조.

www.kci.go.kr

을 발휘해서 도덕적 선택을 할 수 있는데, 이런 도덕적 선택은 의식과 결합된 자율성을 통해서 가능하다.[8] 결국 인간의 도덕적 속성은 의식에서 비롯하는 자율성에 있으며, 의식은 사회적 생물학적 메커니즘을 통해 진화한 것이므로 기계적으로 복제할 수 없다는 것이다.

브라이슨은 특히 공감능력이 "인간 사회의 응집 메커니즘으로 진화"해 왔다는 것을 강조한다. 사회적 응집을 위한 일차적 추동 메커니즘인 공감능력은 인간의 사회적 생존을 위해 진화해 온 것이 때문에, 로봇에게도 가능한 합리적 추론에 근거하는 '공평무사'가 아니라 '자기 이해관심'에 뿌리내리고 있다.[9] 이런 공감의 느낌이 자기가 돌보는 대상에 대한 동일화의 느낌을 만들고, 동일화의 상대적 강도가 도덕적 의무의 위계질서를 만든다. 그 위계질서의 최상층에는 우리 자신과 가족이, 그 아래에 이웃과 우리가 공통성을 인정하는 다른 인간이 있다. 따라서 인간이 로봇을 도덕적 고려의 대상에서 배제하는 것은 당연하다.

브라이슨은 도덕적 속성의 원천을 생물학적 진화과정을 통해 형성된 공감적 사회적 정체성에 찾기 때문에, 기술의 발전으로 로봇이 인간과 유사한 행동을 한다고 해도, 그것은 공감이라는 도덕적 속성과 무관하다고 한다. 그녀는 오히려 로봇이 인간과 유사한 행동을 할 때, 인간이 로봇을 과도하게 자신과 동일시하는 경향을 우려한다. 이런 동일화는 로봇을 '우리 사회의 참여자'로 믿게 해서 도덕적 판단을 할 때 기계에 대한 인간의 의무를 과장할 것이기 때문이다. 특히 로봇이 인간과 동일한 의식을 갖게 될 것이라고 하는 특이점 주의자들의 가설은 '기계와의 과도한 동일화'에서 오는 것으로, "더 큰 문제의 징후, 즉 인간성의 본성과 사회적 공감에 기인하는 윤리의 역할에 대한 일반

8) J. Bryson, "Robots Should Be Slaves", in the *Close Engagements with Artificial Companions: Key social, psychological, ethical and design issues*(ed. Y. Wilks, John Benjamins Publishing, 2010), 2-3쪽 참조.

9) J. Bryson, P. Kime, "Just another artifact: Ethics and the empirical experience of AI", in the *Conferecne: Fifteenth international congress on cybernetics*(1998), 386-387쪽 참조.

www.kci.go.kr

적 혼동의 징후"다.[10] 따라서 브라이슨은 로봇공학자들이 로봇을 인간과 유사하는 모습으로 만드는 것에 반대한다. 만약 로봇이 인간과 유사한 기능을 하게 되면, 인간은 로봇을 인간과 혼동하여 중요한 윤리적 개념을 잘못 적용하게 될 것이라는 것이다.[11] 그렇게 되면, 이미 인간들 사이에서 일어나고 있는 '예술품과 정치제도'와 같은 한정된 자원의 분배에 로봇도 참여시키게 됨으로써 인간의 몫이 줄어든다는 것이다. 따라서 브라이슨은 단지 로봇의 도덕적 지위를 부정하는 것을 넘어서, 로봇을 인간과 유사하게 디자인해서 도덕적 존재로 혼동하게 해서는 안된다고 주장한다. 즉, 로봇은 세탁기나 청소기처럼 인간의 편리를 위해 디자인되어야 하고, 형태나 반응에 있어서 인간과 유사하게 디자인해서 정서적 도덕적 반응을 이끌어내면 안된다는 것이다.

에스트라다(Daniel Estrada)는 브라이슨의 이런 입장이 인간의 종적 특성에 근거해서 로봇에 대한 지배를 정당화하는 인간중심주의이자, '포스트제국주의'라고 비판한다.[12] 그는 브라이슨의 입장이 자유주의적 휴머니즘이 보여온 환경과 동물에 대한 인간의 우선성을 로봇에게 전이하고 있을 뿐이고, 결국은 약자에 대한 강자의 억압을 정당화하고 있다고 비판한다. 로렌스(David Lawrence) 또한 인간 종 고유의 내적 속성에 근거해서 로봇을 차별하고 배제하는 것은 자유주의 휴머니즘에 근거하고 있지만, 그런 휴머니즘이 전제하고 있는 생물학적 인간 개념은 정당화되지 않는다고 지적한다.[13] 이런 비판은 인간의 내적 속성에 근거해서 로봇을 차별하는 속성 실재론에 일반적으로 적용될 수 있

10) J. Bryson, P. Kime, 앞의 논문, 387쪽 참조.

11) Nyholm은 이것을 '평가범주의 오류(evaluative category mistakes)'라고 부른다 S. Nyholm, "The medicalization of love and broad and narrow conceptions of well-being", in the *Cambridge Quarterly of Healthcare Ethics*, vol. 24(3)(2015), 337-46쪽 참조.

12) D. Estrada, "Human supremacy as posthuman risk", in the *Journal of Sociotechnical Critique*, vol. 1(1)(2020), 24-25쪽 참조.

13) D. Lawrence, "The Edge of Human? The problem with the posthuman as the 'beyond'", in the *Bioethics*, vol. 31(3)(2017), 171-179쪽 참조. Lawrence는 인간을 포괄하는 생물학적 종으로서의 특성이란 없다고 주장한다.

다. 특히 도덕성을 일종의 진화심리학에 근거지우는 브라이슨의 입장은 보편적 도덕성을 요구하는 휴머니즘의 관점에서도 비판 받을 수 있다. 전통적 휴머니즘은 인간에게 도덕적 지위를 부여하는 고유한 도덕적 속성이 있다고 하는 반면, 브라이슨은 인간에게만 있는 특정한 속성(진화해 온 공감능력)이 도덕적 속성이라고 주장하고 있기 때문이다. 생물학적 진화에 근거한 인간의 고유한 속성을 도덕성의 근거로 삼게 되면, 도덕성은 보편성을 잃는다. 특히 브라이슨은 도덕성을 편파적인 공감에서 찾기 때문에, 동물이나 로봇 뿐 아니라, 공감을 불러일으키지 못하는 다른 인간 집단의 도덕적 지위도 부정할 가능성이 있다.[14]

엘더나 브라이슨의 속성 실재론은 생물학적 인간의 속성을 도덕적 지위의 근거로 제시함으로써, 인간중심주의라는 비판을 피하기 어렵다. 하지만 도덕적 지위 부여의 근거가 되는 도덕적 속성이 존재한다는 주장이 반드시 인간중심주의로 귀결되는 것은 아니다. 슈비츠게벨(Eric Schwitzgebel)과 그라짜(Mara Graza)는 로봇과 인간이 도덕성과 '유관한 차이 (relevant differences)'를 보이지 않는다면 로봇에게 도덕적 지위를 동등하게 부여하지 않는 것은 비도덕적이라고 한다.[15] 만약 A가 B는 받지 않는 특정한 정도의 도덕적 고려를 받아야 한다면, 둘 사이에는 도덕적 지위의 차이를 정당화하는 어떤 유관한 차이가 있어야 한다는 것이다. 그들은 도덕성과 유관한 속성으로 '심리적 속성'과 '사회적 속성'을 제시하는데,[16] '인간 수준의 인공지능(human-grade

14) Bryson은 사우디아라비아의 시민권이 부여된 로봇 소피아에 대한 신랄하게 비판하는데, 이런 쇼는 사우디아라비아에서 벌어지는 실제 시민들의 급박한 권리 박탈 문제를 회피하는 수단이 될 수 있다는 것이다. Vincent, "Pretending to Give Robots Citizenship Helps No One," in *the The Verge*, October 28, 2017. 참조. 하지만 도덕성을 자기 이해에 기반한 공감에서 정당화하는 Bryson이 보편적 인권 개념을 정당화하기는 어려워 보인다.

15) E. Schwitzgebel/M. Graza, "A Defense of the Rights of Artificial Intelligences," in the *Midwest Studies in Philosophy*, vol. 39 (1)(2015), 99쪽 참조.

16) Schwitzgebel과 Graza는 "심리적 속성"을 창의성, 감정, 자기 개념, 합리성, 취약성 등으로 내적 경험을 하는 자기의식이라고 하고, "사회적 속성"을 부/모성애, 시민정신, 공

artificial intelligence)'은 인간과 유사한 범용의 추론능력과 쾌고 감수능력이 있기 때문에, 자연적인 인간 존재와 같은 심리적 속성과 사회적 속성을 가질 수 있다고 한다. 따라서 도덕성과 유관한 속성을 갖는 로봇은 인간에게 주어지는 것과 유사한 권리를 가져야 한다.[17] 물론 그들도 현시점의 로봇은 사회적 속성에 있어서는 인간과 비슷한 단계에 도달했지만, 자기 의식을 전제하는 심리적 속성은 아직도 인간의 수준에 이르지 못했다고 본다.

슈비츠게벨과 그라짜의 입장은 인간에게만 있는 속성이 아니라, 도덕적 속성 자체에 집중함으로써 속성 실재론이 갖는 인간중심주의라는 혐의를 어느 정도 벗을 수 있을 것이다. 하지만 심리적 속성이 전제하는 인간과 동등한 수준의 의식의 존재와 관련해서, 언제 로봇이 그러한 의식을 가질 수 있는지, 그리고 그것을 확인하는 방법은 무엇인지를 제시하지 않는다. 이것은 속성 실재론이 갖는 본질적인 한계를 보여주는데, 그것은 속성 실재론이 모두가 동의하는 도덕적 속성을 제시할 수 없고, 속성을 정의한다고 해도 그것을 확인할 방법을 제공할 수 없다는 한계다. 슈비츠게벨과 그라짜가 도덕적 속성이 의식에 의지하고 있다는 것을 인정하지만, 로봇은 아직 이런 의식을 가지고 있지 않다는 입장이라면, 엘더와 니홀름은 로봇이 의식을 가진다면, 도덕적 지위를 갖겠지만, 로봇은 의식을 가질 수 없을 것이라는 다소 애매한 입장이다. 반면에 브라이슨은 로봇은 결코 의식을 가질 수 없으며, 로봇이 의식을 가질 수 있다고 주장하는 초지능주의들은 인류를 협박하고 있다는 입장이다. 하지만 어느 쪽이든, 의식의 유무를 확인할 수 있는 방법을 제시할 수 없다는 점과 로봇이 인간과 달리 의식이 없는 것으로 전제되어야 하는 이유를 설명할 수 없다는 점에서, 독단적 형이상학적 주장이라는 비판을 벗어나기 어려울 것이다.[18]

동체성과 같은 사회적 관계에 요구되는 속성이라고 한다. E. Schwitzgebel, M. Graza, 위의 논문, 100쪽 참조.

17) E. Schwitzgebel, M. Graza, 위의 논문, 101쪽 참조. Schwitzgebel과 Graza는 로봇이 도덕적 지위를 부여받을 수 있게 디자인해야 한다고 주장한다. 즉, 로봇의 능력에 상응하여 사용자의 감정적 반응을 보일 수 있도록 디자인 하고, 로봇을 인간과 같이 취약하게 디자인할 때, 로봇이 인간과 유사한 권리를 인정받을 수 있다는 것이다.

3. 관계적 전회와 윤리적 행동주의

군켈(David Gunkel)은 로봇의 도덕적 지위에 대한 속성 실재론의 접근에 대해서 모두가 동의하는 도덕적 속성이 없고, 이 속성과 관련된 의식을 정의하는 것이 어렵우며, 더욱이 로봇의 의식 여부를 알 수 없다는 점에서 한계가 있다고 한다.[19] 따라서 그는 도덕적 지위 부여의 근거를 정의할 수도 인식할 수 없는 내적 속성에서 외적 사회적 관계로 바꾸는 '관계적 전회(relational turn)'를 요구한다. 그에 따르면, 도덕적 지위는 내적 주관적 속성이 아니라 '객관적으로 관찰가능한' 관계에 의해 결정되어야 한다.[20] 개인은 타인, 동물, 자연환경, 더 나아가 인공적인 존재까지 포함해서 다른 존재와 만나고 상호작용하는 것을 통해서, 그 존재들의 도덕적 지위를 평가할 수 있다.[21] 즉, 도덕적 지위의 부여에서 핵심적 역할을 하는 것은 고립된 존재의 내재적 속성이 아니라 개별 존재들이 다른 존재에 참여하고 반응하는 사회적 상호작용이라는 것이다.

군켈의 '관계적 전회'는 도덕적 고려의 근거로서 인간의 반응과 '개입'을 중시한다. 로봇이 의식을 갖지 않다고 해도 인간이 로봇과 상호적인 교환 관계에 있다면, 그 관계 자체가 가치를 갖는다. 예를 들어, 누군가 로봇을 구입하

---

18) 인공지능 윤리를 다루는 국내 논문에서도 (백종현, 「인간 개념의 혼란과 포스트휴머니즘의 문제」, 『철학사상』, 제58집(서울대학교 철학사상연구소, 2015); 김명식, 「인공지능과 환경윤리: 인공지능의 도덕적, 법적 권리」, 환경철학, 제25집(한국환경철학회, 2018). 참조) 이런 속성주의적 경향이 두드러진다. 이들은 의식의 유무를 도덕적 지위 부여의 기준으로 보면서, 로봇이 의식을 가지는 순간이 로봇을 윤리적 주체로 인정하는 순간이 될 것이라는 입장이다. 특히 김명식은 인공지능에게 도덕적 지위를 부여할 수 있는지를 다루면서, 의식이 없는 존재인 로봇과 관련한 윤리를 기존의 동물윤리 및 환경윤리와 유비하고 있다.

19) D. Gunkel, "No Brainer: Why Consciousness Is Neither a Necessary nor Sufficient Condition for AI Ethics," in the *AAAI Spring Symposium: Towards Conscious AI Systems*, http://ceur-ws.org/Vol-2287/paper9.pdf. 2-3쪽 참조.

20) D. Gunkel, 위의 논문, 4쪽 참조.

21) Gunkel은 "타자"와의 만남이 갖는 도덕적 중요성을 강조한 Levinas에 기대어, 존재론적 결정을 넘어서는 관계의 방식을 강조한다. D. Gunkel, 위의 논문, 5쪽 참조.

고 함께 지낸다면, 로봇의 특징과 태도를 이해하게 되어 로봇에 대한 그의 태도와 행동도 변화할 것이다. 이러한 상호작용을 통해서 그 사람은 로봇과 사랑이나 우정의 관계를 형성하고, 그 관계에 만족하게 된다. 로봇이 의식을 갖는지 여부는 관계 맺는 사람의 만족과 무관하고, 중요한 것은 상호작용이다. 군켈은 '관계적 전회'를 통해서 속성에 근거하지 않고, 우정을 비롯한 친밀한 관계 일반의 가치를 충분히 설명할 수 있다고 한다. 우정의 가치가 우정의 관계에 참여하는 당사자들의 반응과 개입에 있기 때문에, 인간 사이의 우정의 가치와 인간과 로봇 사이의 우정의 가치에 우열은 없고, 단지 관계 맺음에서 오는 친밀성의 범위와 정도에 차이가 있을 뿐이다.

군켈과 마찬가지로 코켈버그(Mark Coeckelbergh)는 우정에서 중요한 것은 관계 맺을 때 상대방이 보여주는 '외양(appearance/나타남)'이라고 한다.[22] 코켈버그에 따르면 로봇의 외양은 단순한 장식이나 디자인에 지나는 것이 아니라 인간과 로봇 간의 관계 형성에 있어 결정적인 역할을 하는데, 로봇이 어떤 외양을 가지고 있는지에 따라 인간이 로봇을 어떻게 인식하고 상호작용할지 좌우하기 때문이다. 로봇이 인간과 닮은 외양을 지닐수록 사람들은 그 로봇을 더 쉽게 인간처럼 느끼고, 그에 맞는 감정적 또는 도덕적 반응을 보일 가능성이 커진다. 로봇의 외양이 인간의 도덕적 태도와 결합해서 로봇에 대한 책임, 신뢰, 도덕적 고려 등이 형성되는 것이다. 코켈버그는 외양이 '실제'로 어떤 것을 표현하는가 하는 것보다, 그 외양이 로봇에 대한 인간의 인식과 관계에 어떤 영향을 미치는지에 주목한다. 로봇의 외양은 그것이 실제로 인지능력이나 감정을 가지고 있든 없든 상관없이 인간과의 관계를 형성하는 데 있어서 중요한 역할을 한다는 것이다.[23]

---

22) M. Coeckelbergh, "Is it wrong to kick a robot? Towards a relational and critical robot ethics and beyond", in the *What Social Robots Can and Should Do*(ed. J. Seibt, M. Norskov, S. Schackk Andersen, 2016). 7-8쪽 참조. 이와 관련해서 신상규는 로봇의 타자성을 인정해야 한다는 점을 강조하면서, 구체적 삶의 관계 속에서 로봇에게 도덕적 지위가 귀속될 수 있다고 한다. 신상규, 「인공지능의 도덕적 지위와 관계론적 접근」, 『철학연구』, 제149집(대한철학회, 2019), 261-263쪽 참조.

군켈과 코켈버그의 관계적 접근은 최소한 속성 실재론이 해결할 수 없는 '타인의 마음의 문제'를 벗어날 수 있다. 이제 도덕적 지위의 근거는 인식할 수 없는 특정한 속성이 아니라, 두 당사자 사이의 관계에 있기 때문이다.[24] 이런 '사회적-관계적 접근'에 대해 니홀름은 도덕적 고려에 있어서는 외적 행동 뿐 아니라 그것을 통해서 상대가 처하게 되는 내적인 상태, 즉 고통받거나 행복한 상태가 여전히 중요하다고 비판한다. 즉, 타인과의 상호작용이 도덕적으로 적절한지 여부는 그들의 마음의 속성과 상태에 의존한다는 것이다. 사람들은 타인과 상호작용할 때, 자신의 주관적 상태, 즉 "우리 마음에 있는 것"을 서로 나누고 싶어한다. 관계적 접근은, 타인의 마음이나 감정을 알 수 없다고 하는 타인의 마음의 문제를 너무 과장하면서 친밀한 관계가 요구하는 내적 소통의 측면을 무시하고 있다는 것이다.[25]

관계적 접근에 대한 이러한 비판과 더불어 관계적 접근은 도덕성의 핵심을 관계에 두기 때문에, 개인이 경험하는 외부 존재와의 모든 상호작용을 도덕적인 것으로 간주하게 될 가능성이 있다. 즉, 관계적 접근은 도덕적 지위의 여부를 단지 사회적 맥락의 차원으로 환원하기 때문에, 도덕적으로 의미 있는 상호작용과 도덕적으로 중요하지 않은 혹은 의미 없는 상호작용 사이의 구별을 할 수 없다. 예를 들어, 나와 친밀한 반려 동물이나 사회적 로봇에 대해서는 도덕적 고려를 하고 도덕적 의무를 기꺼이 질 수 있지만, 자기와 상호작용이 없는 다른 개별 인간이나 집단에 대해서는 도덕적 지위를 부인하거나 적어도 무시할 수 있다. 브라이슨이 도덕성을 공감에 두면서 편파적 도덕을 옹호했던

23) M. Coeckelbergh, "Robot Rights? Towards a Social-Relational Justification of Moral Consideration", in the *Ethics Inf Technol*, vol. 12(2010), 209-221쪽 참조.

24) Coeckelbergh는 로봇이 도덕적 지위를 갖기 위해 심리적 자각이나 의식을 가질 필요는 없다고 보며, 그들이 실제로 마음을 가지고 있는지 여부는 관계적 윤리의 핵심적인 질문이 아니라고 한다. 로봇의 도덕적 중요성은 마음이 있느냐 없느냐와 무관하게 인간과의 관계에서 만들어진다는 것이다.

25) S. Nyholm, *Human and Robots: Ethics, Agency, and Anthropomorphism* (Rowman & Littlefield, 2020), 169-171쪽 참조.

www.kci.go.kr

것처럼, 관계적 접근 역시 도덕적 보편성을 희생하는 것이다. 도덕적 판단이 보편적이기 위해서는, 나의 관점에서 주관적으로 형성된 사회적 관계를 벗어나야 한다는 점에서 관계적 접근은 한계를 갖는다.[26]

이러한 비판과 별도로, 관계적 접근은 로봇과 인간의 '동등한' 도덕적 지위를 인정하는 것이 아니라, 로봇을 '도덕적 피동자(moral patient)'의 지위 두기 때문에 아리스토텔레스적인 진정한 우정을 옹호하기 어렵다. 로봇과 인간의 우정은 기껏해야 인간의 즐거움이나 유용성을 위한 수단에 그치며, 그 자체로 '좋은 것'인 '덕의 우정'이 될 수 없기 때문이다. 실제로 코켈버그는 사회적 관계의 존재론을 채택함으로써 로봇을 우리 공동체의 '타자'로 받아들일 가능성을 허용하지만, 그런 수용이 인간 사회에 가져올 위험에 대해서도 우려한다. 코켈버그는 특히 인간 행위자로서 '우리에게 나타나는' 로봇을 보건분야에서 금지해야 한다고 주장하는데, 로봇이 인간 행위자를 대신하게 된다면 돌봄 노동자의 일자리를 뺏을 뿐 아니라, 환자에게 좋은 돌봄의 기회를 박탈하기 때문이다.[27] 그도 로봇과의 관계보다는 인간과의 관계가 더 좋다는 것을 인정하는 것이다. 따라서 관계적 접근은 도덕성의 근거에 대해서는 속성실재론과 다른 입장을 보이지만, 로봇과 인간 사이에 진정한 우정은 가능하지 않다고 보는 점에서는 같다고 할 수 있다. 반면에 다나허는 로봇과 인간 사이의 아리스토텔레스적인 '덕의 우정'이 가능하다고 주장하면서, 관계적 관점이 가진 이러한 한계를 극복하려고 한다.

다나허는 행위자의 내적 속성이 아니라, 특정하게 나타나는 일관된 행위 자

---

26) 신상규는 관계적 접근이 도덕적 상대주의를 함축한다는 비판에 대해, 관계적 접근이 구체적인 경험의 관계의 중요성을 강조하지만, 이런 관계의 중첩적이고 중층적인 방식을 인정하고 다양한 관점을 수용한다는 점에서 상대주의에 빠지지 않고 객관주의를 옹호할 수 있다고 한다. 즉, 관계적 접근은 모든 관점을 동등하게 좋은 관점으로 인정하는 것이 아니라, 특정한 관점을 다른 것보다 낫게 평가할 수 있다는 것이다. 신상규, 앞의 논문, 266-267쪽 참조.

27) M. Coeckelbergh, "Artificial agents, good care, and modernity", in the *Theoretical Medical Bioethics*, vol. 36(2015), 265-277쪽 참조.

www.kci.go.kr

체를 도덕적 고려의 대상으로 해야 한다는 자신의 입장을 '윤리적 행동주의(ethical behaviorism)'로 부른다. 그는 로봇이 중요한 도덕적 지위를 가진다고 널리 동의되는 다른 존재(즉, 인간)와 대체로 수행적으로 등가적이라면, 로봇에게 그 존재와 동일한 도덕적 지위를 주는 것이 옳고 정당하다고 주장한다.[28] 로봇의 도덕적 지위 부여에 있어서 로봇의 내면에서 무엇이 진행되고 있는지는 중요하지 않고, 로봇이 도덕적 지위를 갖는 동물이나 인간과 유사한 행동을 한다면 동등한 도덕적 지위를 주어야 한다는 것이다.[29] 다나허는 두 행위자의 관계가 아니라, 특정한 관계에서 수행되는 일관된 행동을 진정한 우정의 조건이라고 보는 점에서 속성 실재론과 다르지만, 또한 관계 자체가 아니라 관계가 요구하는 행동을 우정의 근거로 본다는 점에서 관계적 접근과도 다르다. 관계적 접근은 도덕적 고려에 있어서 실제 인간이 대상과 맺고 있고 있는 관계, 그리고 그 관계에 의해 인간 자신에게 생긴 만족감이나 책임감 등에 주목하는 반면, 다나허는 우정이나 도덕적 지위를 가능하게 하는 내적 속성은 관찰가능한 행위의 일관된 수행으로 확인될 뿐이라는 입장이다.[30] 군켈은 도덕적 관계에 있어서 만남과 개입이라는 요소를 중시하고, 코켈버그는 상대의 '나타남(외양)'을 강조하지만, 이것이 구체적으로 무엇인지는 분명하지

---

28) J. Danaher, "The Philosophical Case for Robot Friendship", in the *Journal of Posthuman Studies*, vol. 3(1)(2019), 5-24쪽 참조. David Levy도 Danaher와 마찬가지로 인간과 로봇 사이의 사랑을 논할 때, 그는 로봇이 그들이 우리를 사랑한다고 말하고 그렇게 행동한다면, 우리는 이것을 액면가로 받아들이고 로봇이 우리를 사랑한다고 받아들여야 한다고 주장한다. D. Levy, *Love and Sex with Robots: The Evolution of Human-Robot Relationships* (New York: Harper Perennial, 2008), 11쪽 참조.

29) Danaher는 이것을 '비교원칙'으로 부른다. 즉, 인간-로봇 상호작용을 인간-인간 상호작용과 비교해서 그 행위의 윤리적 함의를 평가해야 한다는 것이다. J. Danaher, "Robotic Rape and Robotic Child Sexual Abuse: Should They Be Criminalised?", in the *Criminal Law and Philosophy*, vol. 11 (1)(2017).

30) 다나허는 인간 행위자의 내적 속성의 존재에 대해 적극적인 주장을 하지 않는다. 도덕적인 내적 속성이 없다는 것이 아니라, 그것을 단지 일관된 행동을 통해서 확인할 수 밖에 없다는 것이다. 따라서 그의 행동주의는 '형이상학적'인 것이 아니라 '윤리적'인 것이다.

www.kci.go.kr

않은데, 관계는 총체적이기 때문에 어느 한 요소를 분리해서 고찰할 수 없기 때문이다. 반면에 다나허는 관계의 평가 기준을 일관된 행동의 수행으로 제시한다는 점에서 관계적 접근이 갖는 주관적이고 일방적인 측면을 극복할 수 있다.

다나허는 자신의 윤리적 행동주의에 근거해서 로봇과 인간 사이에 아리스토텔레스적인 진정한 우정이 가능하다고 주장한다. 만약 로봇이 진정한 친구가 보여줄 수 있는 행동들을 일관되게 수행할 수 있다면 로봇은 인간의 친구가 될 수 있고, 인간과 동등한 도덕적 지위를 누려야 한다. 그는 로봇 윤리 분야에서 제시되어 온 아리스토텔레스적인 진정한 우정, 즉 도덕적 우정의 공통된 필요조건을 네 가지로 제시한다. 가치와 관심을 공유하고, 서로에 대해 존경하며 행복을 기원하는 상호성(mutuality), 서로에게 자신의 진실한 모습을 드러내고, 이것을 선택하거나 조작하지 않는 진실성, 또는 진본성(honesty/authenticity), 서로의 관계가 대체로 평등하고, 어느 한쪽이 지배적이거나 우월하지 않는 평등(equality), 삶의 많은 상이한 영역에서 다양한 방식으로 상호작용하는 다양한 상호작용(diversity of interactions) 등이 그 조건이다.[31]

다나허는 이들 조건 중 평등과 다양한 상호작용은 기술의 발전을 통해서 조만간 충족될 수 있거나, 혹은 이미 충족되고 있는 '기술적 불가능성'이라고 본다. 평등은 권력과 수행능력의 평등인데, 로봇이 권력과 능력의 측면에서 인간과 평등한지 여부는 로봇의 물리적 계산적 자원에 달려있고, 기술적 혁신이 이것을 가능하게 할 것이기 때문이다. 다양한 상호작용의 경우에도, 로봇의 물리적 계산적 능숙성에 달려 있고, 이것도 기술적 혁신이 가능하게 할 것이다. 다나허가 보기에 로봇과 인간의 평등과 다양한 상호작용을 가능하게 하는 기술혁신(능력 향상된 지능과 운동성)은 거의 실현되었고, 단지 그 정도에서 차이가 있을 뿐이다. 하지만 상호성과 진본성의 조건은 좀더 신비로운 정신능력(특히 자기 의식)에 의존하는 것이기 때문에 형이상학적인 불가능성, 또는 '강한 형태의' 기술적 불가능성을 전제하고 있다. '강한 형태의' 기술적

31) J. Danaher, "The Philosophical Case for Robot Friendship", 6쪽 참조.

www.kci.go.kr

불가능성이란, 기술적 가능성이 무한히 멀리 있어서 고려할 필요가 없다는 입장이다.[32] 다나허는 도덕적 속성에 근거해서 도덕적 지위를 부여하는 속성실재론의 입장이 경험적으로 증명될 수 없는 형이상학적 조건을 전제하고 있다고 본다.

다나허는 인간 사이의 우정에서 요구되는 상호성과 진본성이, 우정에 요구되는 행동의 '일관된 수행(consistent performances)'에 지나지 않는다는 점을 지적한다. 로봇이 우정에 필요한 내적 속성을 가졌는지를 인식하는 것은 불가능하고, 이것은 로봇뿐 아니라 인간 사이의 우정에서도 마찬가지이다. 따라서 인식론적으로 접근가능한 외적 행위의 일관된 수행을 통해서 우정을 평가해야 한다. 즉, 인간의 우정의 경우에도 우리가 가정하는 상호성과 진본성의 조건을 충족하는 근거는 인간이 보이는 수행적 표현 뿐이기 때문에, 그런 인식론적 근거는 로봇에 의해서도 충족될 수 있다. 지금 혹은 가까운 미래의 로봇이 상호성과 진본성이 요구한 행동을 일관되게 수행할 수 있다면, 로봇도 우정이 요구하는 상호성과 진본성의 조건을 충족할 수 있다.[33]

다나허는 우정의 조건들 중 상호성과 진본성의 경우에만 기술적 불가능성 논쟁에 있을 뿐, 평등과 상호작용의 다양성은 지금의 기술로도 충족될 수 있다고 본다. 하지만 그가 생각하고 있는 평등이나 다양한 상호작용은 단지 겉으로 드러난 능력에 그치고 있다. 로봇과 인간이 평등하다는 것은 로봇의 도덕적 지위와 관련해서 매우 중요하다. 적어도 아리스토텔레스와 칸트가 덕의 우정, 또는 도덕적 우정에서 요구하는 평등은 도덕적 관계의 본질이라고 할 수 있다. 하지

32) Gunkel은 로봇의 도덕적 지위와 관련한 논쟁에서 로봇권리를 반대하는 입장이 로봇이 의식적 존재가 된다면 로봇에게 권리를 인정해야 한다고 주장하면서, 그런 시기를 무한히 뒤로 미룸으로써 문제를 회피하고 있다고 비판한다. 이것을 그는 '무한한 지연(infinite deferral)'이라고 부르는데, 의식을 가진 로봇은 지금 생각할 필요가 없을 정도로 기술적으로 요원하다는 것이다. D. Gunkel, *Robot Rights*. Cambridge(MA: MIT Press, 2018). 3장2절 참조.

33) Danaher는 자신의 입장이 로봇의 의식 가능성에 대한 어떤 형이상학적 주장이 아니며, 단지 인간의 우정과의 유비를 통해 로봇의 우정의 가능성을 주장할 뿐이라고 한다. 인간들 사이의 우정도 행동으로 확인될 뿐이라는 것이다.

만 다나허는 이 평등을 겉으로 드러난 행위 능력의 유사성으로 이해하고 있다. 다나허가 평등을 '힘과 능력'의 문제로 보고, 기술의 진보가 이 문제를 완화하고 결국 제거할 것이라고 낙관하는 것에 대해 니홀름은 우정이 요구하는 평등은 힘과 능력의 문제가 아니라, 도덕적 평등이고, 이것은 '지위의 평등' 이라고 비판한다.[34] 만약 평등이 능력 표현의 평등이라면, 어떤 사정(장애나 가난 등)으로 인해서 동일한 능력을 보여줄 수 없는 인간의 경우, 평등한 친구가 될 수 없을 것이다. 도덕적 영역에서의 평등은 권리와 도덕적 지위의 평등이다.

4. 도덕적 지위와 도덕적 목적

니홀름의 지적대로, 우정이 요구하는 평등은 권력과 능력에서의 평등이 아니라, '지위 또는 상태(status or standing)'의 평등이다. 울스턴크래프트는 우정과 사랑은 권리와 지위가 동등한 사람들 사이에서만 이루어질 수 있다고 주장하면서, 결혼법이 남자와 여자를 더 평등하게 변화시키지 않는다면, 결혼생활에서 진정한 우정과 사랑을 이룰 수 없다고 한다.[35] 따라서 인간과 로봇 사이에 진정한 우정이 가능하려면, 로봇이 권력과 능력에서 인간과 동등해지는 것이 아니라 도덕적 지위와 권리에 있어서 평등해야 한다. 로봇의 능력이 평균 수준의 인간 능력과 유사하거나 능가하는 오늘날 사회에서 인간과 로봇 사이에 존재하는 불평등은 이런 지위의 불평등인 것이다. 엘더나 브라이슨 같은 속성 실재론자들은 로봇과 인간의 평등한 지위를 갖기 위해서는 인간과 같은 의식을 가져야 하며, 로봇은 의식을 가질 수 없기 때문에 인간과 평등할 수 없다고 주장한다. 반면에, 다나허는 평등의 조건을 외적 행동으로 드러나는

34) S. Nyholm, *Human and Robots: Ethics, Agency, and Anthropomorphism* (Rowman & Littlefield, 2020), 116쪽 참조.

35) M. Wollstonecraft, *Vindication of the Rights of Woman* (Norton & Company, 2009). S. Nyholm, 앞의 책, 116쪽에서 재인용.

www.kci.go.kr

지적 능력이나 감정 표현 능력에서 찾고, 로봇이 인간과 유사하게 행동할 수 있다면 평등한 지위를 가질 수 있다고 본다. 즉, 속성 실재론은 의식이 있다면 평등할 수 있다고 주장하고, 행동주의는 유사한 행위 능력이 평등을 보장한다고 보는 것이다.

로봇의 도덕적 지위 부여를 의식의 유무에 근거 지우는 것에 반대하는 피터슨(Stephen Petersen)은, 로봇에게 의식이 있다고 하더라도 인간에 의해 설계된 존재인 로봇은 인간과 평등할 수 없다고 주장한다. 따라서 브라이슨의 우려와 달리, 의식을 가진 로봇이라고 해도 인간의 노예로 사용하는 것에 도덕적 잘못은 없다. 브라이슨은 인간과 유사하게 제작된 로봇을 노예로 사용하게 되면 인간을 노예로 사용해도 된다는 것을 의미하기 때문에 로봇을 인간과 유사하게 제작해서는 안된다고 하지만, 피터슨은 인간과 유사한 의식을 가진, 철학적으로 인격이라고 부를 수 있는 로봇이라고 하더라도 여전히 노예로 사용하는 것은 도덕적 잘못이 아니라고 한다.[36]

피터슨에 따르면, '설계된 로봇의 노예화(Engineered Robot Servitude (ERS))' 즉 인간이 싫어하고 불편해 하는 일을 수행하고 싶어하도록 설계된 비-인간 존재의 노예화는 허용될 수 있다. 만약 어떤 로봇이 인간에게 봉사하고 싶은 내적 욕망이 있고, 로봇이 그것을 의식하며, 그 욕망을 실현하기 위해 노력하고, 욕망이 충족될 때 만족한다면, 자기의 욕망을 의식하는 그런 로봇을 노예로 사용하는 것은 도덕적으로 허용된다는 것이다.[37] 마찬가지로 인간에게 봉사하고 싶어하는 로봇의 합리적 욕망을 부정하거나, 로봇이 더 이상 하고 싶어하지 않는 일을 계속해서 강요하는 것은 비도덕적이다.[38] 이러한 피

36) S. Petersen, "The Ethics of Robot Servitude," in the *Journal of Experimental and Theoretical Artificial Intelligence*, vol. 19(1)(2007); S. Petersen, "Designing People to Serve," in the *Robot Ethics: The Ethical and Social Implications of Robotics*(ed. P. Lin, K. Abney, G. A. Bekey, MIT Press, 2011); S. Petersen, "Is It Good for Them Too? Ethical Concern for the Sexbots,"in the *Robot Sex:Social and Ethcal Implication*(ed. J. Danaher, N. McArthur, 2017) 참조.

37) S. Petersen, "The Ethics of Robot Servitude," 45쪽 참조.

www.kci.go.kr

터슨의 입장은 의식의 유무와 상관없이 로봇의 자율성, 도덕적 지위, 권리 등을 다루고 있기 때문에 속성 실재론의 딜레마를 벗어날 수 있다. 하지만 그는 '설계된' 로봇의 의식과 인간의 의식의 차이를 분명하게 제시하지는 않는다. 로봇의 의식이 인간에 의해 설계된 것이라는 점을 강조되고 있지만, 다나허의 주장처럼, 인간의 의식 역시 자연에 의해 프로그램 되고 만들어진 것이라는 점을 생각한다면 '설계된' 로봇의 의식과 인간의 의식의 차이를 분명히 할 필요가 있다.[39] 본 논문에서 필자는 칸트 윤리학의 목적 개념과 인간성 개념을 통해 로봇의 의식과 인간의 의식의 차이를 해명하는 실마리를 찾고자 한다.

아리스토텔레스와 마찬가지로 칸트도 우정을 맺는 두 사람 사이의 도덕적 지위나 상태의 평등을 강조한다. 칸트는 완전한 우정을 "두 인격이 상호 동등한 사랑과 존경을 바탕으로 결합하는 것" 이라고 하는데,[40] 이때 '사랑'은 다른 사람의 행복에 대한 배려와 그들의 행복을 증진하려는 욕망이다. 반면에 '존경'은 다른 사람을 실천이성과 고유한 의지를 가진 도덕적 행위자로 대하는 태도다. 친구에 대한 사랑은 우리를 그들과 더 가깝게 한다. 하지만 존경은 그들과의 사이에 어떤 거리를 유지하게 만든다.[41] 우리가 친구를 존경한다면, 우리는 그의 소망을 존중하고, 그가 고유한 인격이 될 공간을 주어야 한다. 또한 존경은 우리가 그를 도덕적으로 평등한 존재, 즉 우리 모두가 공유한 도덕적 공동체('목적들의 나라')의 구성원으로서 따라야 하는 법칙이 무엇인지 동등하게 주장할 수 있는 존재로 간주한다는 것을 의미한다. 사랑이 서로를 끌어 당겨서 하나가 되려고 하는 것인 반면에 존경은 서로를 자유롭고 독립적인 존재가 될 수 있도록 거리를 두는 것이다. 그렇기 때문에 곤궁할 때, 친구의 도움을 받는 것은 사랑의 관점에서는 상호적인 호의의 표시로 생각할 수 있지만, 존경의 관점에서는 동등함을 기대할 수 없다. 왜냐하면 이 경우에는 도움

38) S. Petersen, 위의 논문, 52쪽 참조.
39) J. Danaher, "The Philosophical Case for Robot Friendship", 11쪽 참조.
40) I. 칸트, 『도덕형이상학』(김수배 이충진 옮김, 칸트전집 7권(한길사, 2018)), 337쪽 참조.
41) I. 칸트, 위의 책, 348쪽 참조.

www.kci.go.kr

을 받는 쪽이 은혜를 갚을 책무를 지게 되어 상대보다 한 단계 낮아지기 때문이다. 사랑은 '상호 소유의" 감미로움에도 불구하고 연약한 것이기 때문에, 존경을 통해서 사랑을 제한하지 않는다면 우정이 깨지게 되는 것이다.[42] 따라서 칸트의 관점에서 보자면, 로봇과 인간 사이에 진정한 우정이 가능한지 여부는 인간이 로봇을 사랑할 수 있는가에 있는 것이 아니라, 로봇과 상호적인 존경의 의무를 질 수 있는가, 다시 말해 로봇이 도덕적 존재인 인격이 될 수 있는가 여부에 달려 있다.

칸트는 인격을 '도덕적-실천적 이성의 주체'로서의 '인간'이라고 한다. 그렇기 때문에 인격은 모든 '가격'을 뛰어넘고, 절대적 내적 가치인 '존엄성'을 가진다.[43] 이런 절대적 내적 가치 때문에 다른 모든 이성적 존재에게 존경을 강요할 수 있는데, 이 존엄성에 있어서 모든 인격은 평등하기 때문이다.[44] 따라서 인격이 된다는 것은 도덕적 인간으로서 존경의 대상이자, 타인을 자신과 동등한 존재로 평가할 수 있는 존재가 되는 것이다. 존경은 단지 일방적인 호의가 아니며 타인에게 정당하게 요구할 수 있는 도덕적 권리이며, 내가 타인에게 지고 있는 의무다. 칸트에게 인격과 도덕적 존재로서의 인간은 교환되는 개념인데, 그런 인간성에 대한 칸트의 정의는 '인간성 정식'에 가장 분명하게 나타나 있다. 이 정식에서 인간성은 모든 도덕적 존재들이 자기의 주관적 목적 설정에서 침해할 수 없는 궁극적 목적, 목적 자체이다. 칸트는 의지를 "**어떤 법칙에 대한 표상에 맞춰** 행위하도록 자신을 결정하는 능력"[45]으로 정의하는데, 이 자기 규정의 근거가 목적이다. 이어서 칸트는 경향상의 동기를 가진 경험적 인간의 주관적 목적과 모든 이성적 존재의 동인에 근거하는 객관적

42) I. 칸트, 위의 책, 379-380쪽 참조. 그렇다고 해서 사랑과 존경이 서로 대립하는 것은 아닌데, 사랑과 존경은 타인에 대한 덕 의무에 속하기 때문이다. 강은아, 「칸트의 우정론은 우정에 반하는가?」, 『철학연구』, 제62집(고려대학교 철학연구소, 2020), 89-90쪽 참조.

43) I. 칸트, 『도덕형이상학을 위한 기초놓기』(이원봉 옮김, 책세상, 2019), 100쪽 참조.

44) I. 칸트, 『도덕형이상학』, 325쪽 참조.

45) I. 칸트, 『도덕형이상학을 위한 기초놓기』, 86쪽 참조.

www.kci.go.kr

목적을 구별하고, 이 객관적 목적이 도덕법칙의 내용이라고 한다. 도덕법칙의 내용인 객관적 목적은 모든 이성적 존재가 자신의 주관적 목적을 제한하는 궁극적 목적인데, 다름 아닌 자기와 타인 안의 인간성이다.[46]

인간이 궁극적 목적이 될 수 있는 이유는 도덕적 존재로서의 인간만이 자율적 존재이기 때문이다. 도덕의 존재 근거는 자유이고, 인간은 자유롭기 때문에 스스로 부과한 도덕법칙을 스스로 따를 수 있다. 코스가드(Christine Korsgaard)는 이성적 존재로서의 인간성을 일반적인 목적 수립 능력이라고 보아서, 도덕적 목적 수립의 능력인 인격보다 더 넓은 의미로 이해한다. 인간성은 단지 도덕적 목적의 수립 능력에 한정되는 것이 아니라 목적 일반의 선택 능력이라는 것이다. 이성적 존재로서의 인간은 자기가 선택한 것에 가치를 부여할 수 있고, 그가 선택한 가치는 목적 자체로 존중받아야 한다. 어떤 사람이 선택한 목적을 존중하는 것이 바로 그를 목적 자체로 대우하는 것이다.[47] 의식없는 존재인 사물은 스스로 가치를 선택할 수 없지만, 인간은 사물에 가치를 부여하는 존재로서 절대적 가치를 갖는다. 칸트는 의식적 존재인 인간만이 "스스로 목적을 세운다는 점에서" 다른 존재들과 다르다고 한다.[48] 스스로 목적을 세울 수 있다는 점에서 인간은 동물과 구별된다. 이때 인간성이 수립하는 목적은 특별히 도덕적 목적일 필요는 없고, 단지 비본능적 (non-instinctual) 욕구에서 나온 것이기만 하면 된다.[49]

인간성의 개념을 이렇게 볼 때, 적어도 로봇은 칸트적 의미의 인격이 될 수 없다. 물론 피터슨이나 슈비츠게벨과 그라짜가 생각하는 '인간 수준의 인공지능'을 탑재한 로봇은 목적 지향적 활동을 할 수 있을 것이다. 그런 로봇은 목적에 따라 어떤 길을 가야 할지, 어떤 대답을 해야 할지, 어떤 요리를 만들지

46) I. 칸트, 『도덕형이상학을 위한 기초놓기』, 88쪽 참조.
47) C. Korsgaard, *Creating Kingdom of Ends*(Cambridge: Cambridge University Press, 1996), 122-23쪽 참조.
48) I. 칸트, 『도덕형이상학을 위한 기초놓기』, 104쪽 참조.
49) C. Korsgaard, 앞의 책, 112-13쪽 참조.

www.kci.go.kr

선택할 수 있다. 그리고 이들 목적은 다시 더 상위의 목적에 종속될 것이다. 하지만 로봇의 가장 최후의 목적, 즉 인간을 위해서 봉사해야 한다는 목적은 이미 주어져 있어야 한다. 그렇지 않다면, 로봇을 만든 목적이 사라질 것이기 때문이다. 따라서 이런 로봇은 인간에게 봉사하고 싶은 '본능적' 욕망을 갖고 있다고 할 수 있다. 로봇은 자신의 욕망을 의식하지만, 그 욕망의 기원에 대해서는 반성할 수 없이, 단지 자기의 의식 속에 떠오르는 욕망을 실현하기 위해 활동할 것이다.

이런 의미에서 피터슨이 말하는 '인간을 위해 봉사하고 싶은 욕망을 갖도록 제작된' 로봇은, 마치 타인을 사랑하는 경향성을 갖고 있고, 그 경향성의 동기에 따라서만 행동하는 사람과 마찬가지라고 할 수 있다. 따라서 로봇은 아직 절대적 가치가 아니라 상대적 가치만을 갖는다. 로봇의 목적은 인간의 목적에 종속되는 한에서 가치를 갖는 것이다. 물론 인간도 경향성을 가지고 있고, 경향성의 동기에서 행동할 수 있지만, 인간은 자신의 경향성의 목적을 객관적 목적인 인간성에 종속시킬 수 있고, 그때 비로소 도덕적 존재가 된다. 즉, 인간은 경향성의 동기를 의식함에도 불구하고 도덕법칙에 대한 존경의 동기에서 행동할 수 있고, 바로 그 점에서 오직 경향성의 동기만을 가진 동물이나 로봇과 다르다. 도덕적 존재가 되기 위해서는 도덕법칙을 의식하고, 도덕법칙에 대한 존경을 동기로 행동할 수 있어야 한다. 칸트가 완전한 우정은 사랑과 존경의 결합이라고 한 이유도 여기에 있다. 인간이 도덕적 존재가 되기 위해서는 도덕법칙에 대한 존경이 경향성을 제한해야 하는 것처럼, 완전한 우정을 위해서는 상호적 존경이 사랑의 일방성을 제한해야 하는 것이다.

5. 나가는 말

우리는 이상에서 로봇과 인간 사이의 우정의 가능성을 둘러싼 다양한 입장과 각 입장이 갖는 한계를 검토했다. 로봇-우정에 관한 속성 실재론은 우정을

www.kci.go.kr

가능하게 하는 속성이 있고, 로봇은 이것을 가질 수 없기 때문에, 혹은 아직 갖지 못했기 때문에 로봇과 인간의 우정을 부정한다. 속성 실재론에 제기되는 가장 중요한 문제는 의식에 근거하는 이들 속성의 존재 혹은 부재를 증명하는 일일 것이다. 다른 한편 관계적 관점이나 윤리적 행동주의는 로봇-우정을 특정한 내적 속성에 근거하지 않고, 단지 객관적으로 확인 가능한 관계나 행동에 근거 짓기 때문에 의식의 존재 증명이 필요 없다는 점에서 속성 실재론의 난문을 피할 수 있다. 하지만 우정에서 우리가 상대에게 요구하는 것은 진정성이라는 점에서 관계적 관점이나 행동주의는 한계가 있다. 하지만 로봇과 인간의 우정을 다룰 때, 우리가 간과하기 쉬운 것은 로봇과 인간은 결코 유비될 수 없는 본질적 차이가 있다는 사실이다. 로봇은 인간이 디자인하고 제작한 것인 반면, 인간은 적어도 인간에 의해서 디자인되고 제작된 존재가 아니다. 로봇을 디자인할 때, 제작자가 설계한 목적은, 로봇의 욕망의 동기가 되고, 로봇의 주관적 목적 설정의 한계가 된다. 이런 로봇의 본질적인 한계는 아시모프의 로봇 3원칙이 잘 보여주고 있다. 반면에 인간에게 주관적 목적 설정의 한계는 목적 설정 능력으로서의 인간성 자체이다. 다른 인간의 목적 설정 능력을 부정하는 목적을 그 자체로 비도덕적인 목적이 된다. 칸트의 '인간성의 정식'은 이것을 잘 보여준다. 따라서 인간성은 모든 의식적 존재의 목적 설정의 한계라는 점에서, 그리고 로봇은 인간의 목적 설정을 제한하는 한계가 될 수 없고, 로봇 자체가 일방적으로 인간에 의해 목적이 제한된다는 점에서 인간과 로봇의 지위는 본질적으로 불평등한 것이다. 따라서 인간과 로봇 사이에는 평등한 도덕적 지위를 요구하는 진정한 우정은 불가능하다.

www.kci.go.kr

참고문헌

강은아.「칸트의 우정론은 우정에 반하는가?」.『철학연구』. 제62집. 고려대학교 철학연구소. 2020.

김명식.「인공지능과 환경윤리: 인공지능의 도덕적, 법적 권리」.『환경철학』. 제25집, 한국환경철학회. 2018.

백종현,「인간 개념의 혼란과 포스트휴머니즘의 문제」.『철학사상』. 제58집. 서울대학교 철학사상연구소. 2015.

신상규.「인공지능의 도덕적 지위와 관계론적 접근」.『철학연구』. 제149집. 대한철학회, 2019.

장미성.「아리스토텔레스의 우정론:『니코마코스 윤리학』8, 9권을 중심으로」.『인간.환경.미래』. 제28집, 인제대학교 인간환경미래연구원. 2022.

Bryson, J., "Robots Should Be Slaves". in the *Close Engagements with Artificial Companions: Key social, psychological, ethical and design issues*(ed. Y. Wilks). John Benjamins Publishing. 2010.

Bryson, J./Kime, P., "Just another artifact: Ethics and the empirical experience of AI". in the *Conference:Fifteenth international congress on cybernetics*, 1998.

Coeckelbergh, M., "Is it wrong to kick a robot? Towards a relational and critical robot ethics and beyond". in the *What Social Robots Can and Should Do*(ed. J. Seibt, M. Morskov, S. Schack Andersen). IOSpress. 2016.

_____, "Robot Rights? Towards a Social-Relational Justification of Moral Consideration". in the *Ethics and Information Technology*. vol. 12. 2010.

_____, "Artificial agents, good care, and modernity". in the *Theoretical Medical Bioethics*. vol. 36(4). 2015.

_____, *Robots and the Moral Landscape*. Routledge. 2020.

Danaher, J., "Robotic Rape and Robotic Child Sexual Abuse: Should They Be Criminalised?". in the *Criminal Law and Philosophy*. vol. 11(1). 2017.

_____, "The Philosophical Case for Robot Friendship". in the *Journal of Posthuman Studies*. vol. 3(1). 2019.

www.kci.go.kr

Elder, A., "False Friends and False Coinage: A tool for navigating the ethics of sociable robots", in the *SIGCAS Computers and Society*. vol. 45(3). 2015.

_____, *Friendship, Robots, and Social Media: False Friends and Second Selves*. Routledge. 2019.

Estrada, D., "Human supremacy as posthuman risk". in the *Journal of Sociotechnical Critique*. vol. 1(1). 2020.

Gunkel, D., "No Brainer: Why Consciousness Is Neither a Necessary nor Sufficient Condition for AI Ethics". in the *AAAI Spring Symposium: Towards Conscious AI Systems*. 2019.

_____, *Robot Rights*. Cambridge. MA: MIT Press. 2018.

Kant, I., 『도덕형이상학』(김수배 이충진 옮김). 칸트전집 7권. 한길사. 2018.

_____, 『도덕형이상학을 위한 기초놓기』(이원봉 옮김). 책세상. 2019.

Korsgaard, C., *Creating Kingdom of Ends*. Cambridge: Cambridge University Press. 1996.

Lawrence, D., "The Edge of Human? The problem with the posthuman as the 'beyond'". in the *Bioethics*. vol. 31(3). 2017.

Levy, D., *Love and Sex with Robots: The Evolution of Human-Robot Relationships*. New York: Harper Perennial. 2008.

Nyholm, S. /Frank, L. E., "From Sex Robots to Love Robots: Is Mutual Love with a Robot Possible?". in the *Robot Sex* (ed. J. Danaher, N. McArthur). MIT press. 2017.

_____, "The medicalization of love and broad and narrow conceptions of well-being". in the *Cambridge Quarterly of Healthcare Ethics*. vol. 24(3). 2015.

_____, *Human and Robots: Ethics, Agency, and Anthropomorphism*. Rowman & Littlefield. 2020.

Petersen, S., "Designing People to Serve". *Robot Ethics: The Ethical and Social Implications of Robotics*(ed. P. Lin, K. Abney, G. A. Bekey). MIT Press. 2011.

_____, "The Ethics of Robot Servitude". in the *Journal of Experimental and Theoretical Artificial Intelligence*. vol. 19(1). 2007.

_____, "Is It Good for Them Too? Ethical Concern for the Sexbots". *Robot Sex: Social and Ehical Implication*(ed. J. Danaher, N. McArthur). MIT

www.kci.go.kr

press. 2017.
Schwitzgebel, E./ Graza, M., "A Defense of the Rights of Artificial Intelligences," in the *Midwest Studies in Philosophy*. vol. 39 (1). 2015.
Vincent, "Pretending to Give Robots Citizenship Helps No One," in *the The Verge*. October 28. 2017.

www.kci.go.kr

Abstract

Can Friendship Between Robots and Humans be Possible?: The Moral Status of Robots and the Meaning of Humanity

Lee, Wonbong

As artificial intelligence's capacity for rational reasoning advances and humanoid robots equipped with AI can express subtle emotions such as joy and anger, the boundary between robots and humans is becoming increasingly blurred. In particular, there is an ongoing debate about the moral status of social robots that aim to establish intimate relationships with humans. Can a robot share love or friendship with a human? If love or friendship is indeed possible between a robot and a human, treating the robot merely as a tool would be immoral, and the robot should be recognized as an equal to humans. Should robots attain moral status equivalent to humans, human-robot relationships will enter an entirely new stage. Alexis Elder argues that robots, which only respond as programmed, cannot provide the "genuine reciprocity" required for friendship, regardless of how sophisticated their responses may be, due to their lack of inner consciousness. However, John Danaher claims that what matters in friendship is not unverifiable consciousness but consistency in performing actions expected of a true friend, something that current or near-future robots can accomplish.

www.kci.go.kr

The opposing views represented by Elder and Danaher base the possibility of friendship with robots – or their moral status – on the presence or absence of "consciousness." On one side, it is argued that robots lack consciousness and thus cannot be moral agents or true friends; on the other side, since consciousness cannot be empirically verified, robots that behave similarly to morally acknowledged humans should possess equivalent moral status. However, we may ask whether the mere existence of consciousness guarantees moral status. According to Kant, consciousness is a necessary but not sufficient condition for moral status. Even if a being is conscious of its own desires and capable of striving to fulfill them, it cannot be a moral being unless it can reflect on the motivation behind those desires. Thus, Kant's concept of humanity as a moral being may offer a new perspective on the debate over the moral status of robots, which has focused heavily on consciousness.

This paper critically examines two opposing views on the moral status of robots: one that bases moral attributes on consciousness (Chapter 2) and another that bases it on relationships or behavior (Chapter 3). By doing so, this paper argues, through Kant's Humanity Formula and the concept of purpose, that the basis for moral status lies not in mere internal attributes like consciousness but in the capacity of consciousness to set moral purposes (Chapter 4).

【Key words】 AI robots, friendship, moral status, Kantian ethics, formula of humanity

논문접수일: 2024년 11월 25일, 심사완료일: 2024년 12월 27일
게재확정일: 2024년 12월 28일

www.kci.go.kr

www.kci.go.kr